



(12) 发明专利申请

(10) 申请公布号 CN 121981296 A

(43) 申请公布日 2026. 05. 05

(21) 申请号 202610104078.0

(22) 申请日 2026.01.26

(71) 申请人 中国移动紫金(江苏)创新研究院有限公司

地址 210031 江苏省南京市江北新区华富路7号江苏省产业技术研究院园区6号楼

申请人 中国移动通信集团江苏有限公司
中国移动通信集团有限公司
南京大学(72) 发明人 刘子昂 张绍群 王钊 梁爽
吕严 马旭

(74) 专利代理机构 北京银龙知识产权代理有限公司 11243

专利代理师 李兆辰

(51) Int.Cl.

G06N 10/60 (2022.01)

G06N 5/04 (2023.01)

G06N 3/09 (2023.01)

G06N 3/0499 (2023.01)


权利要求书2页 说明书14页 附图3页

(54) 发明名称

模型不确定性优化方法、装置、处理设备、产品及介质

(57) 摘要

本申请实施例提供一种模型不确定性优化方法、装置、处理设备、产品及介质,应用于人工智能技术领域。该方法包括:将针对工业检测场景的训练数据通过量子化深度学习模型进行前馈运算,并获取量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩;根据每个隐层的激活变量的一阶矩和二阶矩,确定量子化深度学习模型的前馈损失和不确定性估计值;根据前馈损失和不确定性估计值,更新量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,目标量子化深度学习模型用于对工业检测场景中的相关设备或产品进行检测。采用该方法,能够解决面向工业检测场景的量子化深度学习模型因不确定性估计不准而导致检测效果不佳的问题。



1. 一种模型不确定性优化方法,其特征在于,所述方法包括:

将针对工业检测场景的训练数据通过量子化深度学习模型进行前馈运算,并获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩;

根据每个所述隐层的激活变量的一阶矩和二阶矩,确定所述量子化深度学习模型的前馈损失和不确定性估计值;

根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,所述目标量子化深度学习模型用于对所述工业检测场景中的相关设备或产品进行检测。

2. 根据权利要求1所述的模型不确定性优化方法,其特征在于,所述激活变量包括:激活前变量和激活后变量;

获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩,包括:

按照所述量子化深度学习模型中各个所述隐层的层间顺序,针对每个所述隐层,对所述隐层接收到的第一变量的一阶矩和二阶矩执行线性变换,获得所述隐层的激活前变量的一阶矩和二阶矩,以及,对所述隐层的激活前变量的一阶矩和二阶矩执行非线性变换,获得所述隐层的激活后变量的一阶矩和二阶矩;

其中,在所述隐层为第一隐层的情况下,所述第一变量为输入变量,所述第一隐层为所述量子化深度学习模型中的第一个隐层;

在所述隐层为第二隐层的情况下,所述第一变量为所述第二隐层的上一个隐层的激活后变量,所述第二隐层为所述量子化深度学习模型中除所述第一隐层之外的其他任意隐层。

3. 根据权利要求1所述的模型不确定性优化方法,其特征在于,所述根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,包括:

基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重;

根据所述量子化权重,更新所述量子化深度学习模型的截断阈值;

通过求解不确定性优化问题,获得目标截断阈值,所述不确定性优化问题至少以最小化所述量子化深度学习模型的不确定性估计值为目标;

根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重;

重复执行第一步骤至第二步骤,直至满足预设条件,获得所述目标量子化深度学习模型;

其中,所述第一步骤为所述基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重的步骤;

所述第二步骤为所述根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重的步骤;

所述预设条件包括:所述量子化深度学习模型趋于收敛和/或达到最大迭代次数。

4. 根据权利要求3所述的模型不确定性优化方法,其特征在于,所述不确定性优化问题基于一阶矩对齐函数和二阶矩对齐函数构建;

其中,所述一阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的平均值之差;

所述二阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的方差之差；

所述量子化深度学习模型是对所述全精度模型进行权重量子化处理获得的模型。

5. 根据权利要求3所述的模型不确定性优化方法,其特征在于,所述通过求解所述不确定性优化问题,获得目标截断阈值,包括:

利用网格搜索方法,在预定义的搜索范围内,确定所述目标截断阈值。

6. 根据权利要求3所述的模型不确定性优化方法,其特征在于,所述根据所述量子化权重,更新所述量子化深度学习模型的截断阈值,包括:

根据公式 $\gamma_s = \|W_s\| / N$,更新所述量子化深度学习模型的截断阈值;

其中, γ_s 表示更新后的所述量子化深度学习模型的截断阈值, W_s 表示第s+1次训练前所述量子化深度学习模型的模型参数矩阵, N 表示 W_s 中元素的个数。

7. 一种模型不确定性优化装置,其特征在于,所述装置包括:

第一处理模块,用于将针对工业检测场景的训练数据通过量子化深度学习模型进行前馈运算,并获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩;

第二处理模块,用于根据每个所述隐层的激活变量的一阶矩和二阶矩,确定所述量子化深度学习模型的前馈损失和不确定性估计值;

第三处理模块,用于根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,所述目标量子化深度学习模型用于对所述工业检测场景中的相关设备或产品进行检测。

8. 一种处理设备,其特征在于,包括处理器、存储器及存储在所述存储器上并可在所述处理器上运行的程序,所述程序被所述处理器执行时实现如权利要求1至6任一项所述的模型不确定性优化方法。

9. 一种计算机程序产品,其特征在于,包括计算机指令,所述计算机指令被处理器执行时实现如权利要求1至6中任一项所述的模型不确定性优化方法的步骤。

10. 一种可读存储介质,其特征在于,所述可读存储介质上存储有程序,所述程序被处理器执行时实现如权利要求1至6任一项所述的模型不确定性优化方法中的步骤。

模型不确定性优化方法、装置、处理设备、产品及介质

技术领域

[0001] 本申请涉及人工智能技术领域,具体涉及一种模型不确定性优化方法、装置、处理设备、产品及介质。

背景技术

[0002] 随着工业智能化和数字化制造的持续推进,深度学习技术已广泛应用于工业检测领域,包括产品外观缺陷检测、质量分级、设备状态监测以及异常行为识别等关键环节。相比人工检测,基于深度学习的自动化检测系统在检测精度、效率和一致性方面具有显著优势,已逐渐成为工业生产线中的核心技术支撑。

[0003] 工业检测场景通常对系统的实时性、稳定性和可解释性提出更为严格的要求,且多部署于算力、存储和能耗受限的边缘设备或嵌入式平台,这对深度学习模型的规模与计算复杂度构成了显著约束。权重量子化是当前实现深度学习轻量化部署的主要技术之一,研究表明,量子化深度学习实现了至少16倍的模型压缩和4倍的推理加速,可满足工业现场对低时延和低资源消耗的需求。

[0004] 然而,量子化过程不可避免地引入离散误差和数值近似偏差,导致模型在推理过程中表现出输出波动、预测置信度失真及对噪声与分布变化的敏感性增强等问题。目前,在工业检测等高可靠性应用中,单纯依赖模型预测结果而缺乏对其不确定性的有效刻画,容易导致误检、漏检或风险决策,进而影响生产安全与产品质量。

发明内容

[0005] 本申请的目的在于提供一种模型不确定性优化方法、装置、处理设备、产品及介质,以解决面向工业检测场景的量子化深度学习模型因不确定性估计不准而导致检测效果不佳的问题。

[0006] 本申请其中一实施例提供一种模型不确定性优化方法,所述方法包括:

[0007] 将针对工业检测场景的训练数据通过量子化深度学习模型进行前馈运算,并获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩;

[0008] 根据每个所述隐层的激活变量的一阶矩和二阶矩,确定所述量子化深度学习模型的前馈损失和不确定性估计值;

[0009] 根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,所述目标量子化深度学习模型用于对所述工业检测场景中的相关设备或产品进行检测。

[0010] 可选地,所述激活变量包括:激活前变量和激活后变量;

[0011] 获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩,包括:

[0012] 按照所述量子化深度学习模型中各个所述隐层的层间顺序,针对每个所述隐层,对所述隐层接收到的第一变量的一阶矩和二阶矩执行线性变换,获得所述隐层的激活前变量的一阶矩和二阶矩,以及,对所述隐层的激活前变量的一阶矩和二阶矩执行非线性变换,

获得所述隐层的激活后变量的一阶矩和二阶矩；

[0013] 其中,在所述隐层为第一隐层的情况下,所述第一变量为输入变量,所述第一隐层为所述量子化深度学习模型中的第一个隐层；

[0014] 在所述隐层为第二隐层的情况下,所述第一变量为所述第二隐层的上一个隐层的激活后变量,所述第二隐层为所述量子化深度学习模型中除所述第一隐层之外的其他任意隐层。

[0015] 可选地,所述根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,包括:

[0016] 基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重；

[0017] 根据所述量子化权重,更新所述量子化深度学习模型的截断阈值；

[0018] 通过求解不确定性优化问题,获得目标截断阈值,所述不确定性优化问题至少以最小化所述量子化深度学习模型的不确定性估计值为目标；

[0019] 根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重；

[0020] 重复执行第一步骤至第二步骤,直至满足预设条件,获得所述目标量子化深度学习模型；

[0021] 其中,所述第一步骤为所述基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重的步骤；

[0022] 所述第二步骤为所述根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重的步骤；

[0023] 所述预设条件包括:所述量子化深度学习模型趋于收敛和/或达到最大迭代次数。

[0024] 可选地,所述不确定性优化问题基于一阶矩对齐函数和二阶矩对齐函数构建；

[0025] 其中,所述一阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的平均值之差；

[0026] 所述二阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的方差之差；

[0027] 所述量子化深度学习模型是对所述全精度模型进行权重量子化处理获得的模型。

[0028] 可选地,所述通过求解所述不确定性优化问题,获得目标截断阈值,包括:

[0029] 利用网格搜索方法,在预定义的搜索范围内,确定所述目标截断阈值。

[0030] 可选地,所述根据所述量子化权重,更新所述量子化深度学习模型的截断阈值,包括:

[0031] 根据公式 $\gamma_s = \|W_s\| / N$,更新所述量子化深度学习模型的截断阈值；

[0032] 其中, γ_s 表示更新后的所述量子化深度学习模型的截断阈值, W_s 表示第s+1次训练前所述量子化深度学习模型的模型参数矩阵, N 表示 W_s 中元素的个数。

[0033] 本申请其中一实施例还提供一种模型不确定性优化装置,所述装置包括:

[0034] 第一处理模块,用于将针对工业检测场景的训练数据通过量子化深度学习模型进行前馈运算,并获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩；

[0035] 第二处理模块,用于根据每个所述隐层的激活变量的一阶矩和二阶矩,确定所述量子化深度学习模型的前馈损失和不确定性估计值；

[0036] 第三处理模块,用于根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,所述目标量子化深度学习模型用于对所述工业检测场景中的相关设备或产品进行检测。

[0037] 本申请其中一实施例还提供一种处理设备,其中,包括处理器、存储器及存储在所述存储器上并可在所述处理器上运行的程序,所述程序被所述处理器执行时实现如上任一项所述的模型不确定性优化方法。

[0038] 本申请其中一实施例还提供一种计算机程序产品,包括计算机指令,所述计算机指令被处理器执行时实现如上任一项所述的模型不确定性优化方法的步骤。

[0039] 本申请其中一实施例还提供一种可读存储介质,其中,所述可读存储介质上存储有程序,所述程序被处理器执行时实现如上任一项所述的模型不确定性优化方法中的步骤。

[0040] 本申请上述技术方案中的至少一个具有以下有益效果:

[0041] 本申请实施例的模型不确定性优化方法中,通过对量子化深度学习模型各层激活变量的一阶矩和二阶矩进行分析,能够更准确地评估模型的不确定性,并将其与前馈损失相结合,指导模型的量子化权重更新。与传统量子化方法相比,本发明能够显著降低模型量子化过程带来的性能损失,提高模型在工业检测场景中的检测精度和可靠性,实现高效、准确的工业设备或产品检测,从而降低生产成本、提升产品质量,并优化生产流程。

附图说明

[0042] 图1为本申请其中一实施例所述模型不确定性优化方法的流程示意图;

[0043] 图2为本申请其中一实施例的经验分布估计和优化效果示意图;

[0044] 图3为本申请其中一实施例的模型不确定性优化方法的整体架构;

[0045] 图4为本申请其中一实施例的精确矩传递 (Exact Moment Propagation, EMP) 算法流程图;

[0046] 图5为本申请其中一实施例的矩对齐 (Moment Alignment, MOMA) 算法流程图;

[0047] 图6为本申请其中一实施例的模型不确定性优化装置的结构示意图。

具体实施方式

[0048] 本申请的说明书和权利要求书中的术语“第一”、“第二”等是用于区别类似的对象,而不适用于描述特定的顺序或先后次序。应该理解这样使用的术语在适当情况下可以互换,以便本申请的实施例能够以除了在这里图示或描述的那些以外的顺序实施,且“第一”、“第二”所区别的对象通常为一类,并不限定对象的个数,例如第一对象可以是一个,也可以是多个。

[0049] 在本发明的各种实施例中,应理解,下述各过程的序号的大小并不意味着执行顺序的先后,各过程的执行顺序应以其功能和内在逻辑确定,而不应对本发明实施例的实施过程构成任何限定。

[0050] 本申请实施例中术语“和/或”,描述关联对象的关联关系,表示可以存在三种关系,例如,A和/或B,可以表示:单独存在A,同时存在A和B,单独存在B这三种情况。字符“/”一般表示前后关联对象是一种“或”的关系。

[0051] 应理解,“与A相应的B”表示B与A相关联,根据A可以确定B。但还应理解,根据A确定B并不意味着仅仅根据A确定B,还可以根据A和/或其它信息确定B。

[0052] 本申请实施例中术语“多个”是指两个或两个以上,其它量词与之类似。

[0053] 另外,本文中术语“系统”和“网络”在本文中常可互换使用。

[0054] 相关技术介绍:

[0055] 在现实工业场景下,对深度学习模型的轻量化部署有巨大的需求,而深度学习在端侧设备的部署受限高计算复杂度与存储需求,权重量子化 (Weight Quantization, WQ) 作为主流的深度学习轻量化部署技术之一,能实现模型压缩和推理加速,但量子化过程也会导致权重信息的丢失,显著放大了模型的认知不确定性 (即表示能力不足引发的预测可信度下降),而这种不确定性会直接降低轻量化模型的可靠性,成为阻碍其在工业场景应用的核心瓶颈。因此亟需针对性的不确定性优化方案。

[0056] 具体的,模型的不确定性是指学习模型对测试样例做出正确预测的置信程度。通常来讲,不确定性越大,模型预测结果的可信度越低,模型的稳定性越差;不确定性越小,模型预测结果的可信度越高,模型的稳定性越强。深度学习模型的不确定性主要包含两类: (1) 偶然不确定性 (Aleatoric Uncertainty), 即由数据本身固有的噪声导致的不确定性; (2) 认知不确定性 (Epistemic Uncertainty), 即由模型本身的知识局限性, 比如模型表示能力不足、数据分布受限等因素导致的不确定性。其中,权重量子化主要影响的是认知不确定性,一方面量子化权重可能会导致信息丢失,降低深度学习模型的表示能力;另一方面量子化深度学习模型可能对某些数据区域表现更不稳定。

[0057] 当前处理深度学习认知不确定性的方法主要分为三类: (1) 基于贝叶斯的不确定性估计 (Uncertainty Estimation, UE), 代表性方法包括贝叶斯网络或者矩传递等。这类方法通过对深度学习模型的权重进行概率建模,从而估计其认知不确定性。这类方法兼具理论分析和技术支撑,但是存在计算开销大、训练复杂等局限性; (2) 基于集成的不确定性估计,代表性方法包括深度集成 (Deep Ensembles)。这类方法训练多个深度学习模型,并在推理时对多个模型的输出进行聚合,以估计认知不确定性。这类方法通常针对某项具体的任务或者数据集进行设计,不具备通用性和理论支撑; (3) 基于启发式指标的不确定性估计,代表性方法包括置信度校准 (Confidence Calibration)、基于能量函数的估计等。这类方法通过启发式地使用温度缩放 (Temperature Scaling) 等方法,使得深度学习模型的输出概率更符合实际的认知不确定性,并避免低置信度区域上的错误预测。这类方法的效果依赖于启发式设计,不具备通用性和理论支撑。

[0058] 目前量子化深度学习模型的不确定性研究仍然有限,开发者通常采用传统的不确定性估计方法评估量子化深度学习模型的不确定性。全精度量化 (Full-precision Quantization, MP) 基于预激活变量服从高斯分布的假设,通过传递均值和近似协方差,以实现量子化深度学习模型的不确定性估计;伪标记深度神经网络 (Pseudo-Labeling Deep Neural Network, PL-DNN) 基于输入服从高斯分布的假设,通过将深度学习模型细分为小型分段线性网络并计算小型网络的一阶和二阶矩的精确解析表达式,以实现量子化深度学习模型的不确定性估计。上述两种方法技术相对成熟,易于部署,但是仍存在依赖强假设、计算开销大、估计不精准等缺点。此外,由于缺乏对量子化权重分布的定制分析,上述方法通常难以支撑有效的不确定性优化,进而导致开发者无从研究如何降低量子化深度学习模型

的不确定性。

[0059] 综上,现有的不确定性估计方法(如贝叶斯建模、模型集成或启发式策略)均存在根本缺陷,例如,贝叶斯方法计算开销过大;集成法通用性差且无理论支撑;启发式方法依赖无效假设。针对量子化模型的MP与PL-DNN等方案部署简单,却依赖于强假设(如高斯分布),导致其估算精度不足且计算冗余,且未对量子化权重分布进行定制化分析,难以有效驱动不确定性优化,导致开发者难以系统性提升模型的可信度。因此,如何精准估计量子化深度学习模型的不确定性并实现高效优化是深度学习轻量化部署相关研究的重要问题。

[0060] 随着技术的发展,使用深度学习模型解决工业检测任务逐渐成为智能制造领域的主流方式。然而,在现实开发和部署中通常会遭遇两方面的难题。一方面,工业检测场景通常部署于算力、存储和能耗受限的边缘设备或嵌入式平台,而高性能的深度学习往往伴随高计算复杂度与高存储需求,限制了其在端侧设备和工业制造等资源受限场景上的应用潜力;另一方面,工业检测场景对系统的实时性和稳定性有更高的需求,因此在工业场景上部署的深度学习模型不仅需要实现高性能和高效率计算,还需要确保其系统的稳定性以及其输出的可信度。

[0061] 因此,如何精准估计量子化深度学习模型的不确定性并实现高效优化是面向工业检测场景的深度学习轻量化部署相关研究的重要问题。目前该领域的研究较少,开发者通常采用传统的不确定性估计方法,比如MP、PL-DNN等,衡量量子化深度学习模型的不确定性。传统方法技术相对成熟,易于部署,但是仍存在估计不精准、计算开销大、依赖强假设等缺点。此外,由于缺乏对量子化权重的分布进行分析,传统方法通常不能支撑有效的不确定性优化,进而导致开发者无从研究如何高效降低量子化深度学习模型的不确定性。因此,有必要开发面向量子化深度学习模型的不确定性精准估计与高效优化方法。

[0062] 下面将结合本申请实施例中的附图,对本申请实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本申请一部分实施例,并不是全部的实施例。基于本申请中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本申请保护的范围。

[0063] 为本申请针对面向工业检测场景的量子化深度学习模型因不确定性估计不准而导致检测效果不佳的问题,提供一种模型不确定性优化方法、装置、处理设备、产品及介质。

[0064] 如图1所示,本申请其中一实施例提供一种模型不确定性优化方法,包括:

[0065] 步骤101,将针对工业检测场景的训练数据通过量子化深度学习模型进行前馈运算,并获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩。

[0066] 步骤102,根据每个所述隐层的激活变量的一阶矩和二阶矩,确定所述量子化深度学习模型的前馈损失和不确定性估计值。

[0067] 这里,前馈损失衡量的是模型在给定输入数据时,预测结果与真实标签之间的差距,因此,前馈损失是训练过程中用于优化模型参数的重要指标。

[0068] 需要说明的是,可以将最后一个隐层激活后变量的一阶矩作为该量子化深度学习模型的预测值(即预测结果),将最后一个隐层激活后变量的二阶矩作为该量子化深度学习模型的不确定性估计值。

[0069] 步骤103,根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,所述目标量子化深度学习模型用于对所

述工业检测场景中的相关设备或产品进行检测。

[0070] 该实施例中,通过对量子化深度学习模型各层激活变量的一阶矩和二阶矩进行分析,能够更准确地评估模型的不确定性,并将其与前馈损失相结合,指导模型的量子化权重更新。与传统量子化方法相比,本发明能够显著降低模型量子化过程带来的性能损失,提高模型在工业检测场景中的检测精度和可靠性,实现高效、准确的工业设备或产品检测,从而降低生产成本、提升产品质量,并优化生产流程。

[0071] 一些实施例中,所述激活变量包括:激活前变量和激活后变量。上述的获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩,具体包括:

[0072] 按照所述量子化深度学习模型中各个所述隐层的层间顺序,针对每个所述隐层,对所述隐层接收到的第一变量的一阶矩和二阶矩执行线性变换,获得所述隐层的激活前变量的一阶矩和二阶矩,以及,对所述隐层的激活前变量的一阶矩和二阶矩执行非线性变换,获得所述隐层的激活后变量的一阶矩和二阶矩。

[0073] 其中,在所述隐层为第一隐层的情况下,所述第一变量为输入变量,所述第一隐层为所述量子化深度学习模型中的第一个隐层;在所述隐层为第二隐层的情况下,所述第一变量为所述第二隐层的上一个隐层的激活后变量,所述第二隐层为所述量子化深度学习模型中除所述第一隐层之外的其他任意隐层。

[0074] 需要说明的是,如图2所示,本发明实施例可以通过执行EMP算法,实现对模型状态变量(也即激活变量)的一阶矩和二阶矩进行逐层传递。在一些示例中,EMP算法可在模型推理阶段进行。

[0075] 具体而言,针对每一个隐层,可以先执行EMP算法的线性变换,即根据当前层接受变量(也即第一变量)的一阶矩和二阶矩,通过EMP算法的线性变换,计算获得当前层激活前变量的一阶矩和二阶矩。然后,再执行EMP算法的非线性变换,即根据将当前层激活前变量的一阶矩和二阶矩,通过EMP算法的非线性变换,计算获得当前层激活后变量的一阶矩和二阶矩。这样,可以按照层间顺序,依次针对每个隐层重复执行上述的线性变换、非线性变换,从而实现激活变量的一阶矩和二阶矩的逐层传递。其中,接受变量在模型第一层为输入变量(也即模型的初始输入变量),接受变量在后续层为当前层的前一层的激活后变量。

[0076] 需要说明的是,如图2所示,本发明实施例提出的这种面向量子化深度学习模型不确定性估计的EMP算法包括数据传递、线性矩传递和非线性矩传递,其中,两步矩传递计算均存在闭式解,且与推理阶段的数据传递同时进行。区别于传统的不确定性估计方法,本发明实施例中的EMP算法具有不依赖强假设、估计效率高、估计精确等优点,具体表现如下:
(1) EMP算法仅传递深度学习模型中变量的一阶矩和二阶矩,无需计算真实分布,也无需依赖分布假设;
(2) 区别于传统MP算法中每个权重服从一个分布的假设,EMP法的线性矩传递采用同一层权重服从同一分布且仅执行线性运算,可极大地缩减计算复杂度;
(3) 区别于贝叶斯类算法中对参数分布的近似计算,EMP算法的非线性矩传递具有闭式解,可实现精准估计。

[0077] 上述步骤102中,根据每个所述隐层的激活变量的一阶矩和二阶矩,确定所述量子化深度学习模型的前馈损失和不确定性估计值,具体可以是量子化深度学习模型的最后一层的激活后变量的一阶矩和二阶矩,将其中的一阶矩作为该量子化深度学习模型的预测值,根据该预测值与真实标签确定前馈损失,将其中的二阶矩作为该量子化深度学习模型

的不确定性估计值。

[0078] 一些实施例中,步骤103,所述根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,具体包括以下步骤:

[0079] 步骤1031,基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重。

[0080] 需要说明的是,在执行步骤103之前,需要准备面向工业检测场景的训练数据集,并将量子化深度学习模型的参数初始化,再通过执行前馈运算,计算获得前馈损失和不确定性估计值,基于量子化深度学习训练方法更新量子化深度学习模型的量子化权重。

[0081] 具体的,步骤1031中,可计算损失函数 $L(y, Q(x; T_s))$,进而基于前馈损失和梯度下降算法,更新量子化权重,该过程可用如下公式表示: $W_{s+1} = W_s + \eta \frac{\partial L(y, Q(x; T_s))}{\partial T_s}$ 。其中, W_s

表示第s+1次训练前所述量子化深度学习模型的模型参数矩阵(当未进行更新时,该矩阵表示初始模型参数矩阵), W_{s+1} 表示通过第s+1次训练更新的量子化深度学习模型的模型参数矩阵,(x, y)表示训练数据, y 表示真实标签, $Q(x; T_s)$ 表示量子化深度学习模型的预测结果, T_s 表示量子化深度学习模型的量子化权重, η 表示学习率。

[0082] 步骤1032,根据所述量子化权重,更新所述量子化深度学习模型的截断阈值。

[0083] 在一些具体示例中,所述根据所述量子化权重,更新所述量子化深度学习模型的截断阈值,包括:根据公式 $\gamma_s = \|W_s\| / N$,更新所述量子化深度学习模型的截断阈值;其中, γ_s 表示更新后的所述量子化深度学习模型的截断阈值, W_s 表示第s+1次训练前所述量子化深度学习模型的模型参数矩阵, N 表示 W_s 中元素的个数。

[0084] 步骤1033,通过求解不确定性优化问题,获得目标截断阈值,所述不确定性优化问题至少以最小化所述量子化深度学习模型的不确定性估计值为目标。

[0085] 这里,通过求解上述不确定性优化问题,可求解量子化深度学习模型的全精度权重,并获得目标截断阈值。

[0086] 在一些具体示例中,所述不确定性优化问题基于一阶矩对齐函数和二阶矩对齐函数构建;其中,所述一阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的平均值之差;所述二阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的方差之差;所述量子化深度学习模型是对所述全精度模型进行权重量子化处理获得的模型。

[0087] 该不确定性优化问题可以表示为: $\gamma_{s+1} = \operatorname{argmin}_{\gamma} |g_3(\gamma, W_s)| + \lambda |g_4(\gamma, W_s)|$ 。

[0088] 其中, γ_{s+1} 表示目标截断阈值, $g_3(\gamma, W_s)$ 表示一阶矩对齐函数, $g_4(\gamma, W_s)$ 表示二阶矩对齐函数。

[0089] 这里,可根据全精度模型和量子化深度学习模型的不确定性估计值,通过矩对齐的方式,将全精度模型和量子化深度学习模型的一阶矩和二阶矩进行对齐,进而建立针对量子化模型的不确定性优化问题,其中可优化参数为量子化深度学习模型的量子化权重。

[0090] 在一些具体示例中,所述通过求解所述不确定性优化问题,获得目标截断阈值,包括:利用网格搜索方法,在预定义的搜索范围内,确定所述目标截断阈值。

[0091] 步骤1034,根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重。

[0092] 这里,利用目标截断阈值,对量子化深度学习模型的全精度权重进行截断,从而更新量子化深度学习模型的量子化权重。

[0093] 具体的,可根据公式 $T_{s+1} = \text{sgn}_{\gamma_{s+1}}(W_{s+1})$,更新量子化权重,其中, T_{s+1} 表示更新后的量子化权重, $\text{sgn}_{\gamma_{s+1}}(\cdot)$ 表示以 γ_{s+1} 为截断阈值的示性函数, γ_{s+1} 表示目标截断阈值。

[0094] 步骤1035,重复执行第一步骤至第二步骤(也就是步骤1031至步骤1034),直至满足预设条件,获得所述目标量子化深度学习模型。其中,所述第一步骤为所述基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重的步骤;所述第二步骤为所述根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重的步骤;所述预设条件包括:所述量子化深度学习模型趋于收敛和/或达到最大迭代次数。

[0095] 也就是说,通过重复执行上述步骤1031至步骤1034,直至量子化深度学习模型收敛或者达到最大迭代轮数,结束训练,输出最终的目标量子化深度学习模型。

[0096] 需要说明的是,如图3所示,本发明实施例可以通过执行MOMA算法,实现对量子化深度学习模型的不确定性优化。该MOMA算法的核心为基于EMP算法得到的不确定性估计值和矩对齐建立不确定性优化问题,并对该优化问题进行求解。区别于传统的优化算法,本发明实施例所提供的MOMA算法在训练阶段发挥作用,而无需对模型进行二次训练,且具有不依赖强假设、可兼容于权重量子化训练过程等优点,能够有效降低量子化深度学习模型的不确定性。

[0097] 具体的,该MOMA算法可包括以下步骤:模型初始化;更新权重和截断阈值;建立不确定性优化问题;使用网格搜索方法求解该优化问题,并更新截断阈值;更新量子化权重。其中,不确定性优化问题的建立和解法具体包括:基于前馈损失函数和梯度下降算法,更新模型权重和截断阈值;建立不确定性最小化优化问题,该优化问题通过矩对齐,能够兼顾预测准确率和不确定性;之后,可通过网格搜索等成熟算法,更新截断阈值和量子化权重。

[0098] 如图4所示,展示了本发明实施例所提供的MOMA算法的不确定性优化效果,通过提供两个比率的直方图,直观地展示了MLP-2上相关的不确定性差异。这里,仅绘制了[0,500]的比率范围,该范围收集了相对于方差比率的99%的经验点。其中,蓝色和橙色区域分别表示深度学习模型和相对应的量子化深度学习模型的不确定性比率的直方图。通过观察可以发现,对于所有训练集中的样本,不确定性比率皆大于1.4,这表明无论是否使用MOMA算法,深度学习模型的不确定性在使用权重量子化之后都会增加。此外,橙色条呈现很明显的衰减走势,即在横轴值较低时直方图频率较高,在横轴值较高时直方图频率较低,这表明本发明实施例所提出的MOMA算法有效地降低了模型的不确定性。

[0099] 下面对本发明实施例提供的模型不确定性优化方法的相关内容进行举例说明。

[0100] 如图5所示,为本发明实施例的模型不确定性优化方法的整体架构。需要说明的是,在执行本发明上述实施例中提供的模型不确定性优化方法之前,可以基于工业检测场景的训练数据集,训练一个工业检测场景下的深度学习模型(也就是上述的全精度模型)和一个与之相对应的量子化深度学习模型,也可以理解为需要执行预训练过程。之后,将输入数据(如面向工业检测场景的训练数据集中的数据)喂给预训练好的全精度模型和量子化深度学习模型,根据层间顺序计算每个隐层的激活前和激活后变量值,可在全精度模型和量子化深度学习模型的推理阶段实现数据传递;通过执行EMP算法,可输出模型全精度模型和量子化深度学习模型的不确定性估计值;通过执行MOMA算法,可优化该量子化深度学习

模型的不确定性。如此,可实现面向工业检测场景的量子化深度学习模型不确定性精确评估及其高效优化,提升量子化深度学习模型在资源受限场景下输出的准确率和可信度,进而增强模型的稳定性。

[0101] 如图2所示,本发明实施例中的面向量子化深度学习模型的不确定性估计EMP算法主要包括如下步骤:

[0102] B1,将量子化深度学习模型预训练至收敛;

[0103] 之后,对量子化深度学习模型进行数据传递,并判断是否完成数据传递:若已完成,则结束循环,输出不确定性估计值;若未完成数据传递,则随着数据传递过程,根据层间顺序执行数据传递计算。

[0104] B5,估计接收变量的经验分布;

[0105] B2,将接收变量转化为激活前变量(该步骤为线性计算);

[0106] B6,执行线性矩传递,将接受变量的一阶矩和二阶矩传递到激活前;

[0107] B3,将激活前变量转化为激活后变量(该步骤为非线性计算);

[0108] B7,执行非线性矩传递,将激活前变量的一阶矩和二阶矩传递到激活后;计算该层激活后变量的二阶矩,将该层激活后变量的二阶矩作为该层的不确定性估计值。

[0109] 重复计算上述步骤,直到判断完成数据传递,结束循环,并输出最后一层激活后变量的二阶矩作为量子化深度学习模型的不确定性估计值。

[0110] 需要说明的是,上述步骤B2、B3、B4与步骤B5、B6、B7是两路并行的过程,其执行过程并不限于上述举例中步骤的先后顺序。其中,步骤B2、B3、B4是量子化深度学习模型的前馈计算,该过程传递的是数据和层间变量;步骤B5、B6、B7是伴随量子化深度学习模型的前馈计算的矩传递过程,该过程中会通过线性矩传递和非线性矩传递逐层计算变量的一阶矩和二阶矩。

[0111] 如图3所示,本发明中面向量子化深度学习模型的不确定性优化MOMA算法主要包括如下步骤:

[0112] 先准备针对工业检测场景的监督数据 (x, y) (也就是训练数据),初始化量子化深度学习模型的参数,其中,量子化深度学习模型的初始化参数采用全精度表示,记为 W_s 。

[0113] 然后,基于监督数据 (x, y) 和MOMA算法训练该量子化深度学习模型,具体训练过程包括:

[0114] 判断是否满足预设条件,即判断量子化深度学习模型的训练是否收敛或者到达设置的最大训练轮数。其中,若已满足预设条件,则表示训练已完成;若模型训练未收敛且未达到设置的最大训练轮数,则继续执行如下训练过程:

[0115] 设置截断阈值 γ_s ,据此计算量子化权重 $T_s = \text{sgn}_{\gamma_s}(W_s)$,并使用当前的量子化权重执行前馈运算;

[0116] 步骤C1:执行EMP算法,输出量子化深度学习模型的不确定性估计值;

[0117] 步骤C2:计算损失函数 $L(y, Q(x; T_s))$,进而根据公式: $W_{s+1} = W_s + \eta \frac{\partial L(y, Q(x; T_s))}{\partial T_s}$,

更新量子化权重。其中, T_s 表示量子化权重, η 表示学习率。

[0118] 步骤C3:更新截断阈值,该过程可表示为: $\gamma_s = \|W_s\| / N$,其中, N 表示 W_s 中元素的个数;

[0119] 进一步的,可建立如下不确定性优化问题:

$$[0120] \quad \gamma_{s+1} = \operatorname{argmin}_{\gamma} |g_3(\gamma, W_s)| + \lambda |g_4(\gamma, W_s)|$$

[0121] 其中, $g_3(\gamma, W_s)$ 表示一阶矩对齐函数, $g_4(\gamma, W_s)$ 表示二阶矩对齐函数, $g_3(\gamma, W_s) = g_2(\gamma, W_s) - g_1(\gamma, W_s)$, $g_4(\gamma, W_s) = g_1(\gamma, W_s) + g_2(\gamma, W_s) - g_3(\gamma, W_s)^2$ 。

[0122] 其中, $g_1(\gamma, W_s) = \sum_{i,j} \tau_{(-\infty, -\gamma)}(W_{ij})/N$, $g_2(\gamma, W_s) = \sum_{i,j} \tau_{(\gamma, +\infty)}(W_{ij})/N$ 。

[0123] 这里, W_{ij} 表示 W_s 的第 i 行第 j 列元素, 且 $\tau_A(x) = 1$ 如果 $x \in A$ 。可以理解的是, 在函数 g_1 中, A 表示区间 $(-\infty, -\gamma)$, 在函数 g_2 中, A 表示区间 $(\gamma, +\infty)$ 。

[0124] 需要说明的是, 上述优化问题可以通过常见的梯度下降法求解, 可实现高效优化。

[0125] 步骤C4: 利用网格搜索方法, 在搜索范围 $(\gamma_s - \epsilon, \gamma_s + \epsilon)$ 内对其求解, 更新得到新的截断阈值 γ_{s+1} (也就是目标截断阈值)。其中, γ_s 表示截断阈值, ϵ 表示用于确定搜索范围的超参数, 通常设置为 $\epsilon = 0.25 |\gamma_s|$ 。

[0126] 步骤C5: 根据公式 $T_{s+1} = \operatorname{sgn}_{\gamma_{s+1}}(W_{s+1})$, 更新量子化权重, 其中, T_{s+1} 表示更新后的量子化权重, $\operatorname{sgn}_{\gamma_{s+1}}(\cdot)$ 表示以 γ_{s+1} 为截断阈值的示性函数;

[0127] 之后, 使用更新后的量子化权重 T_{s+1} 执行前馈运算;

[0128] 步骤C6: 执行EMP算法, 输出量子化深度学习模型的不确定性估计值;

[0129] 重复执行上述步骤, 直到量子化深度学习模型训练收敛或者达到设置的最大训练轮数, 结束循环, 完成训练, 并输出量子化深度学习模型和其不确定性估计值。

[0130] 需要说明的是, 通过上述步骤C1-C6, 可记录量子化深度学习模型在训练过程中的量子化参数值、模型输出以及该模型的不确定性估计值。其中, 通过执行C3中的不确定性优化步骤, 量子化深度学习模型的不确定性估计值将随着训练过程不断降低, 因此量子化深度学习模型输出的可信度将不断提高, 量子化深度学习模型的稳定性也持续增强。

[0131] 本发明的上述实施例中, 主要包含面向量子化深度学习模型不确定性估计的EMP算法和不确定性优化的MOMA算法两部分。其中, EMP算法不仅可以有效估计量子化深度学习模型的不确定性, 且相较传统的MP方法, 其对于预训练深度学习模型的不确定估计更加精准, 可在推理阶段发挥作用, 可输出量子化深度学习模型的不确定性估计值; MOMA算法可在训练阶段发挥作用, 通过参与训练量子化深度学习模型, 能够有效降低量子化深度学习模型的不确定性。

[0132] 需要说明的是, 本发明实施例提出的EMP算法不需要依赖强分布假设, 可以对量子化深度学习模型的不确定性实现高效、精准估计, 可广泛应用于大多数工业检测场景, 具有很强的实用性。在37个工业检测数据上的实验结果表明, 相较于传统方法, EMP的估计速度平均提升近75%, 并实现了几乎理想的估计性能, 有较好的应用效果。本发明实施例提出的MOMA算法可以有效降低量子化深度学习模型的不确定性。在37个工业检测数据上的实验结果表明, MOMA算法可以将深度学习模型的不确定性降低68.05%~98.54%。综上所述, 本发明实施例所提出的模型不确定性优化方法, 实现了面向量子化深度学习模型的不确定性精准估计与高效优化, 可以实现几乎理想的估计性能、高效的估计速度、高效的优化性能等, 具有广泛的应用前景, 可应用于当前快速发展的大模型、人工智能领域, 具备很好的实用性, 能够大幅降低人工智能应用的落地成本。

[0133] 通过上述方案,本发明在保持模型轻量化的同时,显著提高了模型在工业检测场景下的检测精度,降低了漏检和误检率,实现了更高的检测精度;通过模型量子化,有效降低了模型的计算复杂度,实现了更快的推理速度,能够满足工业生产线实时检测的需求,实现了更快的推理速度;通过优化模型的不确定性,提高了模型对噪声和干扰的鲁棒性,保证了检测结果的可靠性,实现了更强的鲁棒性。此外,由于量化模型所需的计算资源更少,本发明还能够降低计算成本,为边缘部署提供了可能,实现了更低的计算成本。

[0134] 本申请实施例所述模型不确定性优化方法,针对面向工业检测场景的量子化深度学习模型因不确定性估计不准而导致检测效果不佳的问题,提出了一种模型不确定性优化方法,该方案通过精确建模量子化过程中的不确定性传播,并采用矩对齐(MOMA)优化算法,有效减小了模型量子化带来的性能损失。具体而言,本发明首先利用全精度模型作为参考,计算理想的不确定性分布;然后通过EMP算法,传播激活变量的一阶矩和二阶矩,并利用MOMA算法,使量子化模型的不确定性分布尽可能接近全精度模型。与现有技术相比,本发明具有更高的检测精度、更快的推理速度、更强的鲁棒性和更低的计算成本,显著降低模型量子化过程带来的性能损失,提高模型在工业检测场景中的检测精度和可靠性,能够实现高效、准确的工业设备或产品检测,从而降低生产成本、提升产品质量,并优化生产流程。

[0135] 如图6所示,本申请其中一实施例还提供一种模型不确定性优化装置,所述装置包括:

[0136] 第一处理模块610,用于将针对工业检测场景的训练数据通过量子化深度学习模型进行前馈运算,并获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩;

[0137] 第二处理模块620,用于根据每个所述隐层的激活变量的一阶矩和二阶矩,确定所述量子化深度学习模型的前馈损失和不确定性估计值;

[0138] 第三处理模块630,用于根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,所述目标量子化深度学习模型用于对所述工业检测场景中的相关设备或产品进行检测。

[0139] 该实施例中,通过对量子化深度学习模型各层激活变量的一阶矩和二阶矩进行分析,能够更准确地评估模型的不确定性,并将其与前馈损失相结合,指导模型的量子化权重更新。与传统量子化方法相比,本发明能够显著降低模型量子化过程带来的性能损失,提高模型在工业检测场景中的检测精度和可靠性,实现高效、准确的工业设备或产品检测,从而降低生产成本、提升产品质量,并优化生产流程。

[0140] 可选地,所述激活变量包括:激活前变量和激活后变量;

[0141] 获取所述量子化深度学习模型中每个隐层的激活变量的一阶矩和二阶矩,包括:

[0142] 按照所述量子化深度学习模型中各个所述隐层的层间顺序,针对每个所述隐层,对所述隐层接收到的第一变量的一阶矩和二阶矩执行线性变换,获得所述隐层的激活前变量的一阶矩和二阶矩,以及,对所述隐层的激活前变量的一阶矩和二阶矩执行非线性变换,获得所述隐层的激活后变量的一阶矩和二阶矩;

[0143] 其中,在所述隐层为第一隐层的情况下,所述第一变量为输入变量,所述第一隐层为所述量子化深度学习模型中的第一个隐层;

[0144] 在所述隐层为第二隐层的情况下,所述第一变量为所述第二隐层的上一个隐层的

激活后变量,所述第二隐层为所述量子化深度学习模型中除所述第一隐层之外的其他任意隐层。

[0145] 可选地,所述根据所述前馈损失和所述不确定性估计值,更新所述量子化深度学习模型的量子化权重,获得目标量子化深度学习模型,包括:

[0146] 基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重;

[0147] 根据所述量子化权重,更新所述量子化深度学习模型的截断阈值;

[0148] 通过求解不确定性优化问题,获得目标截断阈值,所述不确定性优化问题至少以最小化所述量子化深度学习模型的不确定性估计值为目标;

[0149] 根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重;

[0150] 重复执行第一步骤至第二步骤,直至满足预设条件,获得所述目标量子化深度学习模型;

[0151] 其中,所述第一步骤为所述基于所述前馈损失和梯度下降算法,更新所述量子化深度学习模型的量子化权重的步骤;

[0152] 所述第二步骤为所述根据所述目标截断阈值,更新所述量子化深度学习模型的量子化权重的步骤;

[0153] 所述预设条件包括:所述量子化深度学习模型趋于收敛和/或达到最大迭代次数。

[0154] 可选地,所述不确定性优化问题基于一阶矩对齐函数和二阶矩对齐函数构建;

[0155] 其中,所述一阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的平均值之差;

[0156] 所述二阶矩对齐函数用于最小化所述量子化深度学习模型与全精度模型最后一层激活变量的方差之差;

[0157] 所述量子化深度学习模型是对所述全精度模型进行权重量子化处理获得的模型。

[0158] 可选地,所述通过求解所述不确定性优化问题,获得目标截断阈值,包括:

[0159] 利用网格搜索方法,在预定义的搜索范围内,确定所述目标截断阈值。

[0160] 可选地,所述根据所述量子化权重,更新所述量子化深度学习模型的截断阈值,包括:

[0161] 根据公式 $\gamma_s = \|W_s\| / N$,更新所述量子化深度学习模型的截断阈值;

[0162] 其中, γ_s 表示更新后的所述量子化深度学习模型的截断阈值, W_s 表示第s+1次训练前所述量子化深度学习模型的模型参数矩阵, N 表示 W_s 中元素的个数。

[0163] 本申请实施例提供的装置,可以执行上述方法实施例,其实现原理和技术效果类似,本实施例此处不再赘述。

[0164] 需要说明的是,本申请实施例中对单元的划分是示意性的,仅仅为一种逻辑功能划分,实际实现时可以有另外的划分方式。另外,在本申请各个实施例中的各功能单元可以集成在一个处理单元中,也可以是各个单元单独物理存在,也可以两个或两个以上单元集成在一个单元中。上述集成的单元既可以采用硬件的形式实现,也可以采用软件功能单元的形式实现。

[0165] 所述集成的单元如果以软件功能单元的形式实现并作为独立的产品销售或使用时,可以存储在一个处理器可读取存储介质中。基于这样的理解,本申请的技术方案本质上

或者说对现有技术做出贡献的部分或者该技术方案的全部或部分可以以软件产品的形式体现出来,该计算机软件产品存储在一个存储介质中,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备等)或处理器(processor)执行本申请各个实施例所述方法的全部或部分步骤。而前述的存储介质包括:U盘、移动硬盘、只读存储器(Read-Only Memory,ROM)、随机存取存储器(Random Access Memory, RAM)、磁碟或者光盘等各种可以存储程序代码的介质。

[0166] 本申请其中一实施例还提供一种处理设备,其中,包括处理器、存储器及存储在所述存储器上并可在所述处理器上运行的程序,所述程序被所述处理器执行时实现如上任一项所述的模型不确定性优化方法。

[0167] 其中,所述处理设备的处理器上运行的程序,执行所述模型不确定性优化方法的具体实施方式,可以参阅所述模型不确定性优化方法的详细说明,在此不再重复描述。

[0168] 另外,本申请具体实施例还提供一种可读存储介质,其上存储有程序,该程序被处理器执行时实现上述模型不确定性优化方法实施例的各个过程,且能达到相同的技术效果,为避免重复,这里不再赘述。其中,所述的可读存储介质,可以是处理器能够存取的任何可用介质或数据存储设备,包括但不限于磁性存储器(例如软盘、硬盘、磁带、磁光盘(MO)等)、光学存储器(例如CD、DVD、BD、HVD等)、以及半导体存储器(例如ROM、EPROM、EEPROM、非易失性存储器(NAND FLASH)、固态硬盘(SSD))等。

[0169] 本申请实施例还提供一种计算机程序产品,包括计算机指令,该计算机指令被处理器执行时实现上述模型不确定性优化方法实施例的各个过程,且能达到相同的技术效果,为避免重复,这里不再赘述。

[0170] 可选地,本申请实施例可采用在一个或多个其中包含有计算机可用程序代码的计算机可用存储介质(包括但不限于磁盘存储器、CD-ROM、光学存储器等)上实施的计算机程序产品的形式。

[0171] 本申请实施例所述计算机程序产品,所包括的计算机指令在被处理器执行时实现如上所示方法实施例的各个过程,且能够达到相同的技术效果,为避免重复,这里不再赘述。

[0172] 需要说明的是,在本文中,术语“包括”、“包含”或者其任何其他变体意在涵盖非排他性的包含,从而使得包括一系列要素的过程、方法、物品或者装置不仅包括那些要素,而且还包括没有明确列出的其他要素,或者是还包括为这种过程、方法、物品或者装置所固有的要素。在没有更多限制的情况下,由语句“包括一个……”限定的要素,并不排除在包括该要素的过程、方法、物品或者装置中还存在另外的相同要素。

[0173] 需要说明的是,此说明书中所描述的许多功能部件都被称为模块/子模块,以便更加特别地强调其实现方式的独立性。

[0174] 本申请实施例中,模块/子模块可以用软件实现,以便由各种类型的处理器执行。举例来说,一个标识的可执行代码模块可以包括计算机指令的一个或多个物理或者逻辑块,举例来说,其可以被构建为对象、过程或函数。尽管如此,所标识模块的可执行代码无需物理地位于一起,而是可以包括存储在不同位里上的不同的指令,当这些指令逻辑上结合在一起时,其构成模块并且实现该模块的规定目的。

[0175] 实际上,可执行代码模块可以是单条指令或者是许多条指令,并且甚至可以分布

在多个不同的代码段上,分布在不同程序当中,以及跨越多个存储器设备分布。同样地,操作数据可以在模块内被识别,并且可以依照任何适当的形式实现并且被组织在任何适当类型的数据结构内。所述操作数据可以作为单个数据集被收集,或者可以分布在不同位置上(包括在不同存储设备上),并且至少部分地可以仅作为电子信号存在于系统或网络上。

[0176] 在模块可以利用软件实现时,考虑到现有硬件工艺的水平,所以可以以软件实现的模块,在不考虑成本的情况下,本领域技术人员都可以搭建对应的硬件电路来实现对应的功能,所述硬件电路包括常规的超大规模集成(VLSI)电路或者门阵列以及诸如逻辑芯片、晶体管之类的现有半导体或者是其它分立的元件。模块还可以用可编程硬件设备,诸如现场可编程门阵列、可编程阵列逻辑、可编程逻辑设备等实现。

[0177] 以上所述的是本申请的优选实施方式,应当指出对于本技术领域的普通人员来说,在不脱离本申请所述原理前提下,还可以作出若干改进和润饰,这些改进和润饰也应视为本申请的保护范围。




图1




图2




图3





图4



本发明 = 不确定性估计 + 不确定性优化

图5




图6