



(12) 发明专利申请

(10) 申请公布号 CN 122019101 A

(43) 申请公布日 2026. 05. 12

(21) 申请号 202610156273.8

(22) 申请日 2026.02.03

(71) 申请人 一汽奔腾汽车股份有限公司

地址 130012 吉林省长春市高新开发区蔚山路4888号

(72) 发明人 郭迦 薛强 周林 曹阳 金叙龙
高泽磊

(74) 专利代理机构 北京超凡宏宇知识产权代理有限公司 11463

专利代理师 徐丽

(51) Int. Cl.

G06F 9/48 (2006.01)

G06F 9/50 (2006.01)

G06N 3/0495 (2023.01)

G06N 5/04 (2023.01)


权利要求书2页 说明书12页 附图2页

(54) 发明名称

车载多模态大模型的端侧动态优化方法、装置及电子设备

(57) 摘要

本发明提供了一种车载多模态大模型的端侧动态优化方法、装置及电子设备,包括:对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型;使用轻量化模型处理车载多模态输入数据,以执行推理任务;基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置;基于动态配置通过轻量化模型执行计算,产生中间计算结果;对中间计算结果进行检测与复用;基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。该方式中,通过动态量化与异构算力调度,在确保关键任务精度的同时显著降低功耗与延迟;结合中间结果复用与边缘自适应更新,实现了端侧模型的高效、实时、鲁棒推理。



1. 一种车载多模态大模型的端侧动态优化方法,其特征在于,所述方法包括:
对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型;
使用所述轻量化模型处理车载多模态输入数据,以执行推理任务;
在执行推理任务的过程中,基于所述推理任务的任务上下文与所述车载端侧设备的运行状态,对所述轻量化模型的推理计算资源进行动态配置;
基于所述动态配置通过所述轻量化模型执行计算,产生中间计算结果;
在连续推理任务中,对所述中间计算结果进行检测与复用;
基于执行推理任务的本地反馈与车载环境信息,对所述轻量化模型进行自适应更新。
2. 根据权利要求1所述的方法,其特征在于,所述对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型,包括:
将所述原始多模态大模型分解为语音编码模块、视觉编码模块和文本解码模块;
对所述语音编码模块和所述视觉编码模块进行知识蒸馏,将所述语音编码模块和所述视觉编码模块的中间层特征映射至一个共享特征空间;
使用轻量级网络替换所述原始多模态大模型中的所述语音编码模块、视觉编码模块和文本解码模块中的一个或多个,以生成所述轻量化模型。
3. 根据权利要求1所述的方法,其特征在于,所述对所述轻量化模型的推理计算资源进行动态配置,包括:
基于所述任务上下文的安全等级和所述运行状态中的温度或负载信息,为所述轻量化模型动态选择并应用对应的量化精度级别;
基于预先建立的硬件性能画像,将所述轻量化模型的不同计算子图动态调度至NPU、GPU或CPU执行。
4. 根据权利要求3所述的方法,其特征在于,所述基于所述任务上下文的安全等级和所述运行状态中的温度或负载信息,为所述轻量化模型动态选择并应用对应的量化精度级别,包括:
若所述推理任务为安全关键型且设备温度低于预先设置的温度阈值,则应用第一量化精度级别;
若所述推理任务为非关键型且系统负载高于预先设置的第一负载阈值,则应用第二量化精度级别;
所述第一量化精度级别高于所述第二量化精度级别。
5. 根据权利要求3所述的方法,其特征在于,所述基于预先建立的硬件性能画像,将所述轻量化模型的不同计算子图动态调度至NPU、GPU或CPU执行,包括:
实时监测NPU、GPU和CPU的处理器负载;
当所述NPU的处理器负载高于预先设置的第二负载阈值时,将后续待处理的、所述轻量化模型中的计算密集型算子或子图调度至GPU执行。
6. 根据权利要求1所述的方法,其特征在于,所述在连续推理任务中,对所述中间计算结果进行检测与复用,包括:
计算当前输入数据与历史输入数据在所述轻量化模型指定网络层的特征相似度;
若所述特征相似度超过预先设置的相似度阈值,则复用为所述历史输入数据缓存的、所述指定网络层及后续层的中间计算结果。

7. 根据权利要求1所述的方法, 其特征在于, 所述基于执行推理任务的本地反馈与车载环境信息, 对所述轻量化模型进行自适应更新, 包括:

监控所述推理任务的任务执行错误率及所述车载环境信息的变化;

当所述任务执行错误率持续超过预先设置的错误率阈值或所述车载环境信息发生超过预设幅度的变化时, 冻结所述轻量化模型中语音编码模块和视觉编码模块的参数;

更新所述轻量化模型中文本解码模块的顶层N层神经网络的权重参数; 其中, N为大于等于1的正整数。

8. 一种车载多模态大模型的端侧动态优化装置, 其特征在于, 所述装置包括:

轻量化处理模块, 用于对原始多模态大模型进行轻量化处理, 得到适用于车载端侧部署的轻量化模型;

车载多模态输入数据处理模块, 用于使用所述轻量化模型处理车载多模态输入数据, 以执行推理任务;

动态配置模块, 用于在执行推理任务的过程中, 基于所述推理任务的任务上下文与所述车载端侧设备的运行状态, 对所述轻量化模型的推理计算资源进行动态配置;

中间计算结果产生模块, 用于基于所述动态配置通过所述轻量化模型执行计算, 产生中间计算结果;

检测与复用模块, 用于在连续推理任务中, 对所述中间计算结果进行检测与复用;

自适应更新模块, 用于基于执行推理任务的本地反馈与车载环境信息, 对所述轻量化模型进行自适应更新。

9. 一种电子设备, 其特征在于, 包括处理器和存储器, 所述存储器存储有能够被所述处理器执行的计算机可执行指令, 所述处理器执行所述计算机可执行指令以实现权利要求1至7任一项所述的车载多模态大模型的端侧动态优化方法。

10. 一种计算机可读存储介质, 其特征在于, 所述计算机可读存储介质存储有计算机可执行指令, 所述计算机可执行指令在被处理器调用和执行时, 所述计算机可执行指令促使处理器实现权利要求1至7任一项所述的车载多模态大模型的端侧动态优化方法。

车载多模态大模型的端侧动态优化方法、装置及电子设备

技术领域

[0001] 本发明涉及动态优化技术领域,尤其是涉及一种车载多模态大模型的端侧动态优化方法、装置及电子设备。

背景技术

[0002] 当前,多模态大模型为车载智能座舱带来强大交互能力,但实际部署面临两难选择:将数据上传至云端处理存在隐私泄露、高延迟与网络依赖风险;而将完整模型部署于车端,则受限于芯片算力与功耗,难以实现实时、高精度推理。

[0003] 当前静态模型压缩方法无法适应动态任务与多变环境,导致性能、效率与体验难以兼顾。

发明内容

[0004] 有鉴于此,本发明的目的在于提供一种车载多模态大模型的端侧动态优化方法、装置及电子设备,通过动态量化与异构算力调度,在确保关键任务精度的同时显著降低功耗与延迟;结合中间结果复用与边缘自适应更新,实现了端侧模型的高效、实时、鲁棒推理。

[0005] 第一方面,本发明实施例提供了一种车载多模态大模型的端侧动态优化方法,方法包括:对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型;使用轻量化模型处理车载多模态输入数据,以执行推理任务;在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置;基于动态配置通过轻量化模型执行计算,产生中间计算结果;在连续推理任务中,对中间计算结果进行检测与复用;基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。

[0006] 在本发明较佳的实施例中,上述对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型,包括:将原始多模态大模型分解为语音编码模块、视觉编码模块和文本解码模块;对语音编码模块和视觉编码模块进行知识蒸馏,将语音编码模块和视觉编码模块的中间层特征映射至一个共享特征空间;使用轻量级网络替换原始多模态大模型中的语音编码模块、视觉编码模块和文本解码模块中的一个或多个,以生成轻量化模型。

[0007] 在本发明较佳的实施例中,上述对轻量化模型的推理计算资源进行动态配置,包括:基于任务上下文的安全等级和运行状态中的温度或负载信息,为轻量化模型动态选择并应用对应的量化精度级别;基于预先建立的硬件性能画像,将轻量化模型的不同计算子图动态调度至NPU、GPU或CPU执行。

[0008] 在本发明较佳的实施例中,上述基于任务上下文的安全等级和运行状态中的温度或负载信息,为轻量化模型动态选择并应用对应的量化精度级别,包括:若推理任务为安全关键型且设备温度低于预先设置的温度阈值,则应用第一量化精度级别;若推理任务为非关键型且系统负载高于预先设置的第一负载阈值,则应用第二量化精度级别;第一量化精

度级别高于第二量化精度级别。

[0009] 在本发明较佳的实施例中,上述基于预先建立的硬件性能画像,将轻量化模型的不同计算子图动态调度至NPU、GPU或CPU执行,包括:实时监测NPU、GPU和CPU的处理器负载;当NPU的处理器负载高于预先设置的第二负载阈值时,将后续待处理的、轻量化模型中的计算密集型算子或子图调度至GPU执行。

[0010] 在本发明较佳的实施例中,上述在连续推理任务中,对中间计算结果进行检测与复用,包括:计算当前输入数据与历史输入数据在轻量化模型指定网络层的特征相似度;若特征相似度超过预先设置的相似度阈值,则复用为历史输入数据缓存的、指定网络层及后续层的中间计算结果。

[0011] 在本发明较佳的实施例中,基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新,包括:监控推理任务的任务执行错误率及车载环境信息的变化;当任务执行错误率持续超过预先设置的错误率阈值或车载环境信息发生超过预设幅度的变化时,冻结轻量化模型中语音编码模块和视觉编码模块的参数;更新轻量化模型中文本解码模块的顶层N层神经网络的权重参数;其中,N为大于等于1的正整数。

[0012] 第二方面,本发明实施例还提供一种车载多模态大模型的端侧动态优化装置,包括:轻量化处理模块,用于对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型;车载多模态输入数据处理模块,用于使用轻量化模型处理车载多模态输入数据,以执行推理任务;动态配置模块,用于在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置;中间计算结果产生模块,用于基于动态配置通过轻量化模型执行计算,产生中间计算结果;检测与复用模块,用于在连续推理任务中,对中间计算结果进行检测与复用;自适应更新模块,用于基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。

[0013] 第三方面,本发明实施例还提供一种电子设备,包括处理器和存储器,存储器存储有能够被处理器执行的计算机可执行指令,处理器执行计算机可执行指令以实现上述第一方面的车载多模态大模型的端侧动态优化方法。

[0014] 第四方面,本发明实施例还提供一种计算机可读存储介质,计算机可读存储介质存储有计算机可执行指令,计算机可执行指令在被处理器调用和执行时,计算机可执行指令促使处理器实现上述第一方面的车载多模态大模型的端侧动态优化方法。

[0015] 本发明实施例带来了以下有益效果:

本发明实施例提供了一种车载多模态大模型的端侧动态优化方法、装置及电子设备,通过对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型,使用轻量化模型处理车载多模态输入数据,以执行推理任务,在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置,基于动态配置通过轻量化模型执行计算,产生中间计算结果,在连续推理任务中,对中间计算结果进行检测与复用,基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。该方式中,通过动态量化与异构算力调度,在确保关键任务精度的同时显著降低功耗与延迟,结合中间结果复用与边缘自适应更新,实现了端侧模型的高效、实时、鲁棒推理。

[0016] 本公开的其他特征和优点将在随后的说明书中阐述,或者,部分特征和优点可以

从说明书推知或毫无疑义地确定,或者通过实施本公开的上述技术即可得知。

[0017] 为使本公开的上述目的、特征和优点能更明显易懂,下文特举较佳实施例,并配合所附附图,作详细说明如下。

附图说明

[0018] 为了更清楚地说明本发明具体实施方式或现有技术中的技术方案,下面将对具体实施方式或现有技术描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图是本发明的一些实施方式,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0019] 图1为本发明实施例提供的一种车载多模态大模型的端侧动态优化方法的流程图;

图2为本发明实施例提供的另一种车载多模态大模型的端侧动态优化方法的流程图;

图3为本发明实施例提供的一种车载多模态大模型的端侧动态优化装置的结构示意图;

图4为本发明实施例提供的一种电子设备的结构示意图。

具体实施方式

[0020] 为使本发明实施例的目的、技术方案和优点更加清楚,下面将结合附图对本发明的技术方案进行清楚、完整地描述,显然,所描述的实施例是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0021] 近年来,多模态大模型在智能座舱领域得到了广泛关注。此类模型通过融合语音、图像、文本、传感器等多源数据,实现了从语义理解到情境推理的人机交互能力。例如,代表性开源模型包括GPT-4V、LLaVA、Qwen-VL等,它们通常由视觉编码器(ViT, VisionTransformer)与大型语言模型(LLM, LargeLanguageModel)组合构成。

[0022] 在相关车载系统中,主机厂和供应商通常主要采用以下几种方案来部署多模态模型:

方案A:云端完整部署。原始视频、图像和语音数据上传至云端,云端模型完成特征提取和推理,再将结果返回车端。

[0023] 存在的问题:

1. 隐私与安全风险:车内外摄像头捕捉的图像包含人员面部、姿态、车牌、地理位置等敏感信息,直接上传云端违反可能影响隐私要求。

[0024] 2. 高带宽消耗与不稳定性:多路高清视频流上传占用大量5G带宽,通信质量稍有波动便影响结果时效。

[0025] 3. 高响应延迟:从数据上传、云端计算到结果下发,链路长、延迟高,无法满足座舱内小于2秒的交互要求。

[0026] 方案B:车端完整部署。将整个多模态模型(ViT+LLM)压缩后全部放入车载计算平台运行。

[0027] 存在的问题:

1.算力瓶颈突出:现有SA8295P/Orin等车规级芯片受制于功耗与NPU算力,难以在30fps图像输入和多任务场景下实时运行百亿级参数模型。

[0028] 2.静态压缩精度损失大:统一量化模型无法兼顾不同任务(视觉识别、语义理解等)的精度要求。

[0029] 3.功耗与散热压力高:长时间高负载推理会导致功耗飙升、整机发热严重。

[0030] 4.更新维护困难:模型更新需整包OTA,周期长、成本高。

[0031] 因此,相关技术在端侧实时性、能耗与模型精度之间难以平衡。

[0032] 基于此,本发明实施例提供的一种车载多模态大模型的端侧动态优化方法、装置及电子设备,可以通过对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型,使用轻量化模型处理车载多模态输入数据,以执行推理任务,在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置,基于动态配置通过轻量化模型执行计算,产生中间计算结果,在连续推理任务中,对中间计算结果进行检测与复用,基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。该方式中,通过动态量化与异构算力调度,在确保关键任务精度的同时显著降低功耗与延迟,结合中间结果复用与边缘自适应更新,实现了端侧模型的高效、实时、鲁棒推理。

[0033] 为便于对本实施例进行理解,首先对本发明实施例所公开的一种车载多模态大模型的端侧动态优化方法进行详细介绍。

[0034] 实施例1

本发明实施例提供一种车载多模态大模型的端侧动态优化方法,图1为本发明实施例提供的一种车载多模态大模型的端侧动态优化方法的流程图。如图1所示,该车载多模态大模型的端侧动态优化方法可以包括如下步骤:

步骤S101,对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型。

[0035] 其中,原始多模态大模型:指参数规模庞大(通常为十亿甚至千亿级)、能够同时处理和理解多种模态数据(如文本、图像、语音)的预训练人工智能模型。例如,开源模型LLaVA、Qwen-VL,或GPT-4V等。

[0036] 其中,轻量化模型:指通过对原始大模型进行压缩、剪裁等处理后得到的、参数量和计算量显著减少,但力求保留核心性能的模型版本,旨在适配车载计算平台有限的算力与存储资源。

[0037] 具体地,对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型,可以包括:将原始多模态大模型分解为语音编码模块、视觉编码模块和文本解码模块;对语音编码模块和视觉编码模块进行知识蒸馏,将语音编码模块和视觉编码模块的中间层特征映射至一个共享特征空间;使用轻量级网络替换原始多模态大模型中的语音编码模块、视觉编码模块和文本解码模块中的一个或多个,以生成轻量化模型。

[0038] 其中,原始多模态大模型分解:将复杂的多模态模型解耦为功能相对独立的子网络。这是一种面向部署的结构化分析,为后续的差异化处理(如仅蒸馏视觉与语音部分)奠定基础。

[0039] 其中,知识蒸馏:一种模型压缩技术,通过让轻量化模型模仿大模型的行为或内部特征表示来学习。此处特指跨模态特征蒸馏,目标是让不同模态的编码器输出在语义上对齐到一个公共空间。

[0040] 其中,关于蒸馏,还可以采用多任务蒸馏、自监督学习等方式生成共享特征空间。

[0041] 其中,共享特征空间:一个抽象的概念空间,在此空间中,来自图像(视觉编码器输出)和语音(语音编码器输出)的语义信息被映射为具有相同含义维度的向量,共享特征空间的维度与表示形式不限于单一向量,可以是多维张量或其他嵌入形式。例如,关于“狗”的图片特征向量和“狗”的语音特征向量在该空间中是接近的。这为后续的多模态融合与理解提供了统一的基础,是降低模型复杂度的关键。

[0042] 其中,轻量级网络替换:用结构更精巧、参数更少的网络架构替代原始模型中庞大笨重的模块。例如,用MobileViT、EfficientNet替换原始的Vision Transformer (ViT),用Conformer-Tiny替换原始的Whisper模型。除了直接替换,轻量化手段还可包括但不限于:网络剪枝(移除不重要的神经元连接)、低秩分解(将大矩阵拆解为小矩阵乘积)、以及自动化神经架构搜索(NAS)来寻找最优的轻量子结构。替换“一个或多个”体现了灵活性,例如可能保留强大的文本解码器,仅轻量化视觉和语音编码器。

[0043] 其中,以LLaVA模型为例:

分解:视觉编码器(ViT-L/14),文本解码器(Vicuna-7B),语音部分需额外集成(如Whisper-small)。

[0044] 蒸馏:使用大量图文-语音配对数据训练。目标函数不仅要求轻量化的视觉/语音编码器能完成自身任务(如图像分类、语音识别),还要求它们中间层的特征经过投影后,在共享特征空间中的距离尽可能接近。

[0045] 替换:将ViT-L/14替换为MobileViT-XS(4层),将Whisper-small替换为Conformer-Tiny(3层),文本解码模块保留但冻结底层。最终得到的轻量化模型参数量可大幅度降低,满足端侧部署条件。

[0046] 其中,通过生成轻量化模型不仅显著减少了模型参数量(较原模型减少40%以上),还使得不同任务能够复用底层网络结构,节省存储与计算资源。

[0047] 步骤S102,使用轻量化模型处理车载多模态输入数据,以执行推理任务。

[0048] 其中,车载多模态输入数据:指车辆在运行过程中实时产生的多种传感器数据,典型包括:车内摄像头采集的驾驶员/乘员图像与视频流、麦克风阵列采集的语音指令、车辆外部摄像头采集的道路环境图像、以及车身CAN总线提供的车辆状态信号等。

[0049] 其中,推理任务:指利用所述轻量化模型对输入数据进行处理以得出特定结论或响应的过程。例如:视觉问答(前方路牌是什么)、驾驶员状态识别(疲劳、分心)、语音助手交互、场景语义理解等。

[0050] 步骤S103,在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置。

[0051] 其中,任务上下文:指与当前推理任务相关的属性信息集合,用于指导资源分配策略。其核心包括:1)任务类型(如视觉识别、语义理解);2)功能安全等级(根据ISO 26262标准划分,如ASIL-B的安全关键任务-驾驶员监测,或QM级的娱乐信息任务-音乐推荐);3)实时性要求(延迟预算,如碰撞预警需<100ms,导航查询可容忍1-2s)。

[0052] 其中,车载端侧设备的运行状态:指承载模型推理的车载计算平台(如高通SA8295P、英伟达Orin芯片)的实时物理与逻辑参数。主要包括:1)处理器负载(NPU/GPU/CPU利用率);2)温度(芯片结温);3)功耗;4)内存占用率。

[0053] 其中,推理计算资源:指执行模型推理时可动态调配的软硬件资源总和,主要包括:1)计算精度资源(即量化位宽,决定数值表示的精度与计算速度);2)硬件执行单元资源(NPU、GPU、CPU的计算能力);3)内存与缓存资源。

[0054] 步骤S104,基于动态配置通过轻量化模型执行计算,产生中间计算结果。

[0055] 其中,中间计算结果:指模型在前向传播过程中,网络中间层(非最终输出层)产生的激活值(Activation)或特征图(Feature Map)。这些数据包含了输入数据的抽象表征。

[0056] 步骤S105,在连续推理任务中,对中间计算结果进行检测与复用。

[0057] 具体地,在连续推理任务中,对中间计算结果进行检测与复用,可以包括:计算当前输入数据与历史输入数据在轻量化模型指定网络层的特征相似度;若特征相似度超过预先设置的相似度阈值,则复用为历史输入数据缓存的、指定网络层及后续层的中间计算结果。

[0058] 其中,连续推理任务,如视频流或多轮对话。

[0059] 其中,特征相似度计算:通常使用余弦相似度(Cosine Similarity)或欧氏距离来衡量两个特征向量的相似程度。计算发生在指定的网络层,通常选择能够捕捉到输入数据核心语义、又不过于底层的中间层(例如,视觉编码器的中后层)。

[0060] 其中,特征相似度计算方法除直接比较外,还可采用基于哈希函数的近似匹配、局部敏感哈希(Locality Sensitive Hashing, LSH)等技术。

[0061] 其中,复用:如果当前输入帧与上一帧的相似度超过阈值(例如0.9),则判定场景未发生本质变化。系统将直接读取缓存中存储的、从该指定层开始直至输出层的所有中间激活值,并以此为基础进行后续计算(如融合、解码),完全跳过了对该指定层之前所有层的重复计算。

[0062] 其中,缓存:缓存通常采用固定大小的先进先出(FIFO)或最近最少使用(LRU)队列管理,并需要与车载系统的内存管理单元协同,其最多保留5组激活数据,最大占用不超过20MB,确保在内存紧张时能被安全回收,有效减少了重复计算,提高了多轮语音-视觉交互的流畅度。

[0063] 其中,缓存管理策略除FIFO外,还可采用LRU(Least Recently Used)、LFU(Least Frequently Used)等常见缓存替换算法。

[0064] 例如,在高速公路辅助驾驶场景,摄像头以30fps采集图像。连续帧之间背景变化微小,仅车辆位置略有偏移。系统计算连续帧在某个中间层的特征相似度为0.98,于是复用前一帧90%的计算结果,仅用极少算力完成本帧的目标检测与跟踪,极大提升了效率。

[0065] 步骤S106,基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。

[0066] 其中,本地反馈:指在车端执行推理任务后,可本地记录的性能指标,主要包括:任务准确率/错误率、单次推理时延、任务成功率、以及系统记录的异常日志。

[0067] 其中,车载环境信息:指车辆所处的外部物理环境参数,可通过车身传感器获取,例如:环境光照强度(白天/黑夜/隧道)、背景噪声等级(嘈杂/安静)、天气状况(晴/雨/雾)、

GPS地理位置信息等。

[0068] 具体地,基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新,可以包括:监控推理任务的任务执行错误率及车载环境信息的变化;当任务执行错误率持续超过预先设置的错误率阈值或车载环境信息发生超过预设幅度的变化时,冻结轻量化模型中语音编码模块和视觉编码模块的参数;更新轻量化模型中文本解码模块的顶层N层神经网络的权重参数;其中,N为大于等于1的正整数。

[0069] 其中,在同一推理任务连续三次超过15%,或环境突变(如从白天进入隧道),则触发微调。微调完成后,将权重参数加密上传至云端;云端聚合多车数据后生成新蒸馏模型,通过OTA下发,形成Cloud-Edge联动更新体系。

[0070] 其中,系统持续跟踪两类指标:1)性能指标:如特定任务(“识别停止标志”)的错误率;2)环境协变量:如光照从白天突变为进入隧道。当错误率持续超标其中,或环境突变时,视为模型在当前条件下性能下降,触发更新。

[0071] 其中,冻结语音/视觉编码器:这是出于功能安全与稳定性的考虑。编码器是模型的“感知器官”,一旦被意外修改,可能导致基础感知能力崩溃,引发严重安全隐患。冻结它们确保了感知基础的一致性。

[0072] 其中,更新文本解码器顶层:文本解码器负责“思考和表达”,其顶层网络更关联于具体的任务逻辑和语言风格。更新这部分,相当于让模型在保持相同“世界观”(感知能力)的前提下,调整其“决策和表达方式”,以适应新场景或纠正错误。“N层”是一个可配置参数,例如更新最后1-2层。

[0073] 其中,更新过程:在触发后,系统利用近期在本地收集的、带有隐式或显式反馈的数据(如用户纠正的样本、系统标记的失败案例),进行小规模、低学习率的微调训练(如SGD)。为防止灾难性遗忘,可采用弹性权重巩固等算法。

[0074] 其中,在线微调算法除小批量SGD外,还可采用Adam、RMSprop等其他优化器。

[0075] 例如,一辆车长期在北方干燥环境下行驶,模型对雨天识别不佳。某日行驶至南方多雨地区,雨滴和雾气导致视觉识别错误率上升。系统触发更新,利用在雨天新收集的、识别效果不佳的数据,微调解码器顶层参数,使模型学会在雨天条件下做出更鲁棒的判断,而不会忘记如何识别晴天物体。

[0076] 其中,该机制还可用于实现有限的用户个性化。例如,系统可学习驾驶员特定的语音指令习惯(如用“导航回家”代替“请规划到我住宅的路线”),通过更新解码器相关参数来实现,而无需改变基础的语音识别和地图搜索能力。

[0077] 本发明实施例提供的车载多模态大模型的端侧动态优化方法,可以通过对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型,使用轻量化模型处理车载多模态输入数据,以执行推理任务,在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置,基于动态配置通过轻量化模型执行计算,产生中间计算结果,在连续推理任务中,对中间计算结果进行检测与复用,基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。该方式中,通过动态量化与异构算力调度,在确保关键任务精度的同时显著降低功耗与延迟,结合中间结果复用与边缘自适应更新,实现了端侧模型的高效、实时、鲁棒推理。

[0078] 实施例2

本发明实施例还提供另一种车载多模态大模型的端侧动态优化方法;该方法在上述实施例方法的基础上实现;该方法重点描述对轻量化模型的推理计算资源进行动态配置的具体实现方式。

[0079] 图2为本发明实施例提供的另一种车载多模态大模型的端侧动态优化方法的流程图,如图2所示,该对轻量化模型的推理计算资源进行动态配置,可以包括如下步骤:

步骤S201,基于任务上下文的安全等级和运行状态中的温度或负载信息,为轻量化模型动态选择并应用对应的量化精度级别。

[0080] 其中,量化精度级别:指模型权重和激活值的数值表示位宽。例如,FP32(全精度)、INT8(8位整数)、INT4(4位整数)。位宽越低,计算速度越快、内存占用越少、功耗越低,但可能损失精度。

[0081] 具体地,基于任务上下文的安全等级和运行状态中的温度或负载信息,为轻量化模型动态选择并应用对应的量化精度级别,可以包括:若推理任务为安全关键型且设备温度低于预先设置的温度阈值,则应用第一量化精度级别;若推理任务为非关键型且系统负载高于预先设置的第一负载阈值,则应用第二量化精度级别;第一量化精度级别高于第二量化精度级别。

[0082] 例如,驾驶员注意力监测(安全关键任务)在芯片温度正常时,采用W8A8量化,优先保证识别精度;乘客点播歌曲(非关键任务)在系统负载很高时,采用W4A4量化,优先保障系统流畅性和降低功耗。

[0083] 进一步地,可以对模型中不同敏感度的层采用不同的量化位宽,敏感层用高精度,不敏感层用低精度。

[0084] 进一步地,系统可以学习在不同(任务上下文,设备状态)组合下,选择哪种量化级别能获得最佳的“精度-延时-功耗”综合收益,而非固定的规则。

[0085] 进一步地,当车辆电池电量较低时,可更激进地采用低精度量化以节能。

[0086] 步骤S202,基于预先建立的硬件性能画像,将轻量化模型的不同计算子图动态调度至NPU、GPU或CPU执行。

[0087] 其中,硬件性能画像:一个预先通过大量基准测试建立的数据库或配置文件。它记录了所述轻量化模型的不同计算子图(如一个卷积块、一个注意力层)在目标车载芯片(NPU/GPU/CPU)上运行时的性能数据,包括:执行延迟、功耗、内存占用以及温度影响系数。这是智能调度的决策依据。

[0088] 具体地,基于预先建立的硬件性能画像,将轻量化模型的不同计算子图动态调度至NPU、GPU或CPU执行,可以包括:实时监测NPU、GPU和CPU的处理器负载;当NPU的处理器负载高于预先设置的第二负载阈值时,将后续待处理的、轻量化模型中的计算密集型算子或子图调度至GPU执行。

[0089] 其中,计算密集型算子或子图:指卷积(Convolution)、矩阵乘法(MatMul)等操作。

[0090] 例如,一个多模态任务,其视觉卷积部分在硬件画像中显示在NPU上效率极高,因此被调度至NPU。但当NPU负载超过85%阈值时,调度器将后续新任务中的视觉部分导向GPU,防止NPU过载成为瓶颈。文本生成部分(富含逻辑判断)则被调度至CPU。

[0091] 进一步地,调度时需权衡计算加速收益与数据在CPU、GPU、NPU之间搬运产生的延迟与功耗开销。

- [0092] 进一步地,对最高安全等级的任务,可设置硬件抢占机制,确保其计算资源。
- [0093] 进一步地,不以纯粹延迟最短为目标,而是以“任务完成功耗”或“单位功耗下的计算吞吐量”为调度目标。
- [0094] 其中,通过将实时调度结果反馈至功耗监控模块形成闭环优化,实现了功耗-时延-精度的动态平衡。
- [0095] 作为本申请一实施例:语音与视觉融合任务的动态量化推理流程。
- [0096] 场景:驾驶员询问“前方红色路牌上写的是什么?”。
- [0097] 流程:
摄像头采集图像帧,语音模块将语音转写为文本;
系统识别任务为“视觉问答”,NPU温度65摄氏度,负载78%;
动态量化模块选择 $q = w4a16$;
视觉编码在NPU执行,文本解析在CPU执行;
激活缓存检测连续帧相似度等于0.93,大于0.9,复用第4层后激活;
融合层在共享特征空间Z生成答案“限速60 km/h”;
语音播报结果,端到端耗时1.1秒,功耗降低22%。
- [0098] 作为本申请又一实施例:多任务并发场景下的异构算力优化流程。
- [0099] 场景:同时运行导航、音乐播放、驾驶员状态检测。
- [0100] 流程:
实时负载:GPU75%,NPU空闲45%,CPU60%;
调度决策:
驾驶员检测(视觉类,ASIL B)分配至NPU, $q = w8a16$;
导航语义解析在GPU执行;
音乐指令“下一首”由CPU处理;
激活缓存检测驾驶员面部连续5帧相似度大于0.95,跳过前两层卷积;
三任务并行,整体功耗下降18%,最大时延小于等于1.2秒。
- [0101] 实施例3
对应于上述方法实施例,本发明实施例提供了一种车载多模态大模型的端侧动态优化装置,图3为本发明实施例提供的一种车载多模态大模型的端侧动态优化装置的结构示意图,如图3所示,该车载多模态大模型的端侧动态优化装置可以包括:
轻量化处理模块301,用于对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型。
- [0102] 车载多模态输入数据处理模块302,用于使用轻量化模型处理车载多模态输入数据,以执行推理任务。
- [0103] 动态配置模块303,用于在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置。
- [0104] 中间计算结果产生模块304,用于基于动态配置通过轻量化模型执行计算,产生中间计算结果。
- [0105] 检测与复用模块305,用于在连续推理任务中,对中间计算结果进行检测与复用。
- [0106] 自适应更新模块306,用于基于执行推理任务的本地反馈与车载环境信息,对轻量

化模型进行自适应更新。

[0107] 本发明实施例提供的车载多模态大模型的端侧动态优化装置,可以通过对原始多模态大模型进行轻量化处理,得到适用于车载端侧部署的轻量化模型,使用轻量化模型处理车载多模态输入数据,以执行推理任务,在执行推理任务的过程中,基于推理任务的任务上下文与车载端侧设备的运行状态,对轻量化模型的推理计算资源进行动态配置,基于动态配置通过轻量化模型执行计算,产生中间计算结果,在连续推理任务中,对中间计算结果进行检测与复用,基于执行推理任务的本地反馈与车载环境信息,对轻量化模型进行自适应更新。该方式中,通过动态量化与异构算力调度,在确保关键任务精度的同时显著降低功耗与延迟,结合中间结果复用与边缘自适应更新,实现了端侧模型的高效、实时、鲁棒推理。

[0108] 在一些实施例中,轻量化处理模块,还用于将原始多模态大模型分解为语音编码模块、视觉编码模块和文本解码模块;对语音编码模块和视觉编码模块进行知识蒸馏,将语音编码模块和视觉编码模块的中间层特征映射至一个共享特征空间;使用轻量级网络替换原始多模态大模型中的语音编码模块、视觉编码模块和文本解码模块中的一个或多个,以生成轻量化模型。

[0109] 在一些实施例中,动态配置模块,还用于基于任务上下文的安全等级和运行状态中的温度或负载信息,为轻量化模型动态选择并应用对应的量化精度级别;基于预先建立的硬件性能画像,将轻量化模型的不同计算子图动态调度至NPU、GPU或CPU执行。

[0110] 在一些实施例中,动态配置模块,还用于若推理任务为安全关键型且设备温度低于预先设置的温度阈值,则应用第一量化精度级别;若推理任务为非关键型且系统负载高于预先设置的第一负载阈值,则应用第二量化精度级别;第一量化精度级别高于第二量化精度级别。

[0111] 在一些实施例中,动态配置模块,还用于实时监测NPU、GPU和CPU的处理器负载;当NPU的处理器负载高于预先设置的第二负载阈值时,将后续待处理的、轻量化模型中的计算密集型算子或子图调度至GPU执行。

[0112] 在一些实施例中,检测与复用模块,还用于计算当前输入数据与历史输入数据在轻量化模型指定网络层的特征相似度;若特征相似度超过预先设置的相似度阈值,则复用为历史输入数据缓存的、指定网络层及后续层的中间计算结果。

[0113] 在一些实施例中,自适应更新模块,还用于监控推理任务的任务执行错误率及车载环境信息的变化;当任务执行错误率持续超过预先设置的错误率阈值或车载环境信息发生超过预设幅度的变化时,冻结轻量化模型中语音编码模块和视觉编码模块的参数;更新轻量化模型中文本解码模块的顶层N层神经网络的权重参数;其中,N为大于等于1的正整数。

[0114] 本发明实施例所提供的装置,其实现原理及产生的技术效果和前述方法实施例相同,为简要描述,装置实施例部分未提及之处,可参考前述方法实施例中相应内容。

[0115] 实施例4

本发明实施例还提供了一种电子设备,用于运行上述车载多模态大模型的端侧动态优化方法;参见图4所示的一种电子设备的结构示意图,该电子设备包括存储器400和处理器401,其中,存储器400用于存储一条或多条计算机指令,一条或多条计算机指令被处理器401执行,以实现上述车载多模态大模型的端侧动态优化方法。

[0116] 进一步地,图4所示的电子设备还包括总线402和通信接口403,处理器401、通信接口403和存储器400通过总线402连接。

[0117] 其中,存储器400可能包含高速随机存取存储器(RAM,Random Access Memory),也可能还包括非不稳定的存储器(non-volatile memory),例如至少一个磁盘存储器。通过至少一个通信接口403(可以是有线或者无线)实现该系统网元与至少一个其他网元之间的通信连接,可以使用互联网,广域网,本地网,城域网等。总线402可以是ISA总线、PCI总线或EISA总线等。总线可以分为地址总线、数据总线、控制总线等。为便于表示,图4中仅用一个双向箭头表示,但并不表示仅有一根总线或一种类型的总线。

[0118] 处理器401可能是一种集成电路芯片,具有信号的处理能力。在实现过程中,上述方法的各步骤可以通过处理器401中的硬件的集成逻辑电路或者软件形式的指令完成。上述的处理器401可以是通用处理器,包括中央处理器(Central Processing Unit,简称CPU)、网络处理器(Network Processor,简称NP)等;还可以是数字信号处理器(Digital Signal Processor,简称DSP)、专用集成电路(Application Specific Integrated Circuit,简称ASIC)、现场可编程门阵列(Field-Programmable Gate Array,简称FPGA)或者其他可编程逻辑器件、分立门或者晶体管逻辑器件、分立硬件组件。可以实现或者执行本发明实施例中的公开的各方法、步骤及逻辑框图。通用处理器可以是微处理器或者该处理器也可以是任何常规的处理器等。结合本发明实施例所公开的方法的步骤可以直接体现为硬件译码处理器执行完成,或者用译码处理器中的硬件及软件模块组合执行完成。软件模块可以位于随机存储器,闪存、只读存储器,可编程只读存储器或者电可擦写可编程存储器、寄存器等本领域成熟的存储介质中。该存储介质位于存储器400,处理器401读取存储器400中的信息,结合其硬件完成前述实施例的方法的步骤。

[0119] 本发明实施例还提供了一种计算机可读存储介质,该计算机可读存储介质存储有计算机可执行指令,该计算机可执行指令在被处理器调用和执行时,计算机可执行指令促使处理器实现上述车载多模态大模型的端侧动态优化方法,具体实现可参见方法实施例,在此不再赘述。

[0120] 本发明实施例所提供的进行车载多模态大模型的端侧动态优化方法的计算机程序产品,包括存储了处理器可执行的非易失的程序代码的计算机可读存储介质,所述程序代码包括的指令可用于执行前面方法实施例中所述的方法,具体实现可参见方法实施例,在此不再赘述。

[0121] 所属领域的技术人员可以清楚地了解到,为描述的方便和简洁,上述描述的系统、装置和单元的具体工作过程,可以参考前述方法实施例中的对应过程,在此不再赘述。

[0122] 在本发明所提供的几个实施例中,应该理解到,所揭露的系统、装置和方法,可以通过其它的方式实现。以上所描述的装置实施例仅仅是示意性的,例如,所述单元的划分,仅仅为一种逻辑功能划分,实际实现时可以有另外的划分方式,又例如,多个单元或组件可以结合或者可以集成到另一个系统,或一些特征可以忽略,或不执行。另一点,所显示或讨论的相互之间的耦合或直接耦合或通信连接可以是通过一些通信接口,装置或单元的间接耦合或通信连接,可以是电性,机械或其它的形式。

[0123] 所述作为分离部件说明的单元可以是或者也可以不是物理上分开的,作为单元显示的部件可以是或者也可以不是物理单元,即可以位于一个地方,或者也可以分布到多个

网络单元上。可以根据实际的需要选择其中的部分或者全部单元来实现本实施例方案的目的。

[0124] 另外,在本发明各个实施例中的各功能单元可以集成在一个处理单元中,也可以是各个单元单独物理存在,也可以两个或两个以上单元集成在一个单元中。

[0125] 所述功能如果以软件功能单元的形式实现并作为独立的产品销售或使用,可以存储在一个处理器可执行的非易失的计算机可读取存储介质中。基于这样的理解,本发明的技术方案本质上或者说对现有技术做出贡献的部分或者该技术方案的部分可以以软件产品的形式体现出来,该计算机软件产品存储在一个存储介质中,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备等)执行本发明各个实施例所述方法的全部或部分步骤。而前述的存储介质包括:U盘、移动硬盘、只读存储器(ROM, Read-Only Memory)、随机存取存储器(RAM, Random Access Memory)、磁碟或者光盘等各种可以存储程序代码的介质。

[0126] 最后应说明的是:以上所述实施例,仅为本发明的具体实施方式,用以说明本发明的技术方案,而非对其限制,本发明的保护范围并不局限于此,尽管参照前述实施例对本发明进行了详细的说明,本领域的普通技术人员应当理解:任何熟悉本技术领域的技术人员在本发明揭露的技术范围内,其依然可以对前述实施例所记载的技术方案进行修改或可轻易想到变化,或者对其中部分技术特征进行等同替换;而这些修改、变化或者替换,并不使相应技术方案的本质脱离本发明实施例技术方案的精神和范围,都应涵盖在本发明的保护范围之内。因此,本发明的保护范围应以权利要求的保护范围为准。




图1




图2




图3




图4